


# Modelos basados en autómatas probabilísticos

Bioingeniería I

FI-UNER

# Organización

- Parte I
  - Autómatas determinísticos
  - Autómatas celulares.
  - Aplicación modelos tejido excitable.
- Parte II
  - Autómatas probabilísticos
  - Modelos de Markov.
  - Aplicaciones



# Definición de Autómata


Un Autómata queda especificado por tres conjuntos  $X$ ,  $Y$  y  $E$ ; y dos funciones  $\delta$  y  $\beta$ , donde:

- $X$  es un conjunto finito de entradas
- $Y$  es un conjunto finito de salidas
- $E$  es el conjunto de estados
- $\delta : E \times X \rightarrow E$ , la función de *transición de estado*
  - si en el tiempo  $t$  el sistema está en el estado  $e$  y recibe una entrada  $x$ , entonces en el tiempo  $t+1$  el sistema estará en el estado  $\delta(e, x)$
- $\beta : E \rightarrow Y$ , la función de *salida*
  - el estado  $e$  siempre da lugar a una salida  $\beta(e)$

# Autómatas probabilísticos (AEFP)

- A diferencia de los AEF determinísticos:
  - Pueden albergar una descripción probabilística del fenómeno que modelan → *modelos de señal*
  - 1º nivel de incerteza:
    - En lugar de función de transición de estados se habla de *probabilidades* de transición entre estados.
    - Estados con salida determinística.
  - 2º nivel de incerteza:
    - Cada estado se asocia a uno de los posibles símbolos de un conjunto de salidas mediante su correspondiente *fdp*.

# Ejemplo de AEFP



- Las probabilidades de transición desde el estado  $i$  al estado  $j$  se indican como  $a_{ij}$ .
- A cada estado se asocia un símbolo del conjunto finito de salidas.
- En este ejemplo la salida del estado corresponde simplemente con su número.

# Modelo de Markov


- A este tipo de modelo probabilístico se lo denomina también *modelo de Markov* (MM).
- Si el tiempo transcurre a intervalos discretos se trata de un **MM de tiempo discreto**.
- Si las probabilidades de transición sólo dependen de los estados origen y destino, se está en presencia de un proceso de primer orden o **cadena de Markov**.
- Cuando las probabilidades de transición no se modifican con el tiempo también se habla de una cadena de Markov **homogénea**.

# Modelo de Markov

- Conjunto de estados:  $Q=\{q_1,\dots,q_n\}$
- Vector de probabilidades iniciales:  $\pi=\{\pi_1,\dots,\pi_n\}$ ;  
donde  $\pi_i=P(s_0=q_i)$
- Matriz de probabilidad de transiciones:  $A=\{a_{ij}\}$ ,  
donde  $a_{ij}=P(s_t=q_j|s_{t-1}=q_i)$
- Vector de observaciones (coincide con el número de estado):  $O=\{o_1,\dots,o_T\}$

$$MM: \Lambda = \{A, \Pi\}$$

# Ejemplo



- ¿Qué probabilidad existe de que este modelo genere la secuencia de salida 1, 2, 2, 3, 2, 4?
- La secuencia de estados es la misma: 122324.
- Así, se obtiene la probabilidad total para la secuencia mediante la productoria:

$$p_{122324} = a_{12}a_{22}a_{23}a_{32}a_{24} = \frac{1}{2} \frac{1}{4} \frac{1}{4} \frac{1}{2} \frac{1}{2} = \frac{1}{128}$$

$$A = \{a_{ij}\} = \begin{bmatrix} 0 & 1/2 & 1/2 & 0 \\ 0 & 1/4 & 1/4 & 1/2 \\ 0 & 1/2 & 1/4 & 1/4 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$




# Un ejemplo climático



- Estados:  
1. Lluvia, 2. Nubes, 3. Sol.
- Probabilidad de transición:

$$A = \{a_{ij}\} = \begin{pmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{pmatrix},$$

$$\Pi = \{\pi_i\} = (0.0, 0.0, 1.0).$$




# Un ejemplo climático



- Pregunta: ¿con qué probabilidad el tiempo de 8 días será “sol-sol-sol-lluvia-lluvia-sol-nubes-sol”?
- Probabilidad de la observación  $O = \{3, 3, 3, 1, 1, 3, 2, 3\}$ :

$$\begin{aligned} P(O \mid \text{Modelo}) &= P(3, 3, 3, 1, 1, 3, 2, 3 \mid \text{Modelo}) \\ &= P(3) \cdot P(3|3) \cdot P(3|3) \cdot P(1|3) \cdot P(1|1) \cdot P(3|1) \cdot P(2|3) \cdot P(3|2) \\ &= \Pi_3 \cdot a_{33} \cdot a_{33} \cdot a_{13} \cdot a_{11} \cdot a_{31} \cdot a_{23} \cdot a_{32} \\ &= 1.536 \cdot 10^{-4} \end{aligned}$$



# Modelos ocultos de Markov

- En cada estado de un MM se emite un determinado símbolo del conjunto de salidas posibles.
- Es por esto que un MM es también conocido bajo la denominación de modelo *observable* de Markov: a partir de la salida se puede “observar” en qué estado se encuentra el modelo.
- Para aumentar su capacidad de modelado, se puede hacer que la función que asocia a cada estado una salida sea una distribución de probabilidades sobre todas las posibles salidas.

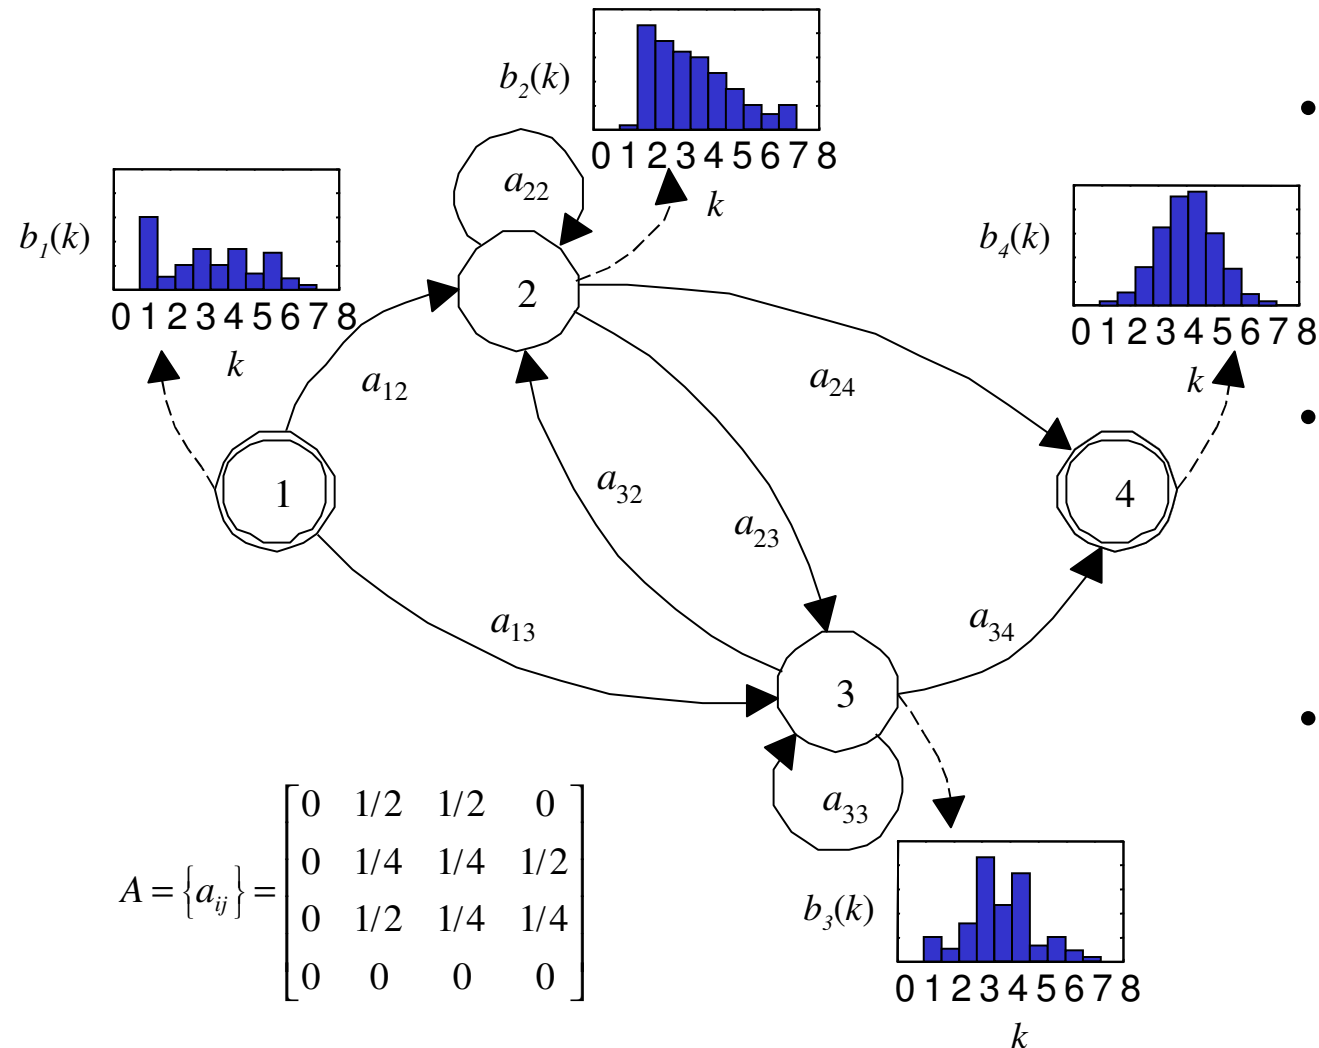
# Modelos ocultos de Markov

- Ahora existirá un nuevo parámetro  $b_j(k)$  que describe la probabilidad de que en el estado  $j$  se observe el símbolo  $k$  del conjunto de salidas.
- En estas condiciones nunca se podrá saber con certeza en qué estado está el modelo observando solamente su salida.
- El funcionamiento interno del modelo queda “oculto” y es por eso que se lo denomina modelo *oculto* de Markov (MOM).

# Procesos estocásticos a dos niveles

- Los MOM son procesos estocásticos a dos niveles:
  - el de los estados, que no es observable,
  - y el de eventos físicos, que sí es observable.
    - »  $B = \{b_j(k)\}$ ;  $j$ : estados,  $k$ : observaciones
- En algunos casos suele hablarse de probabilidades de *emisión* en lugar de probabilidades de *observación*.

# Ejemplo: MM $\rightarrow$ MOM



- Ahora para cada estado existe una *función de distribución de probabilidad*  $b_j(k)$ .
- En este ejemplo el valor más probable para la salida del estado corresponde a su número.
- Es “posible” que pueda generar algunas secuencias similares al MM.

# Ejemplo: dos monedas cargadas

- Estamos en una habitación con una cortina que nos impide ver a una persona que tiene dos monedas cargadas de manera diferente.
- Esa persona lanza repetidamente una u otra (aleatoriamente) al aire y nos informa de si sale cara ( $H$ , por *head*) o cruz ( $T$ , por *tail*):


»  $H H T H T H H \dots$

- No tenemos forma de saber cada  $H$  o  $T$  de qué moneda es:
  - ¿Cómo explicamos/modelamos las secuencias que observamos?



# Ejemplo: dos monedas cargadas

- Podríamos modelar este escenario con un MOM:
  - Cada estado correspondería a una moneda.
  - El hecho de que la persona cambia de moneda aleatoriamente correspondería al hecho de cambiar de estado.
  - La asunción markoviana impone que la probabilidad de tomar una u otra moneda dependa exclusivamente de la última moneda lanzada.



$$P(H) = P_1$$

$$P(T) = 1 - P_1$$

$$P(H) = P_2$$

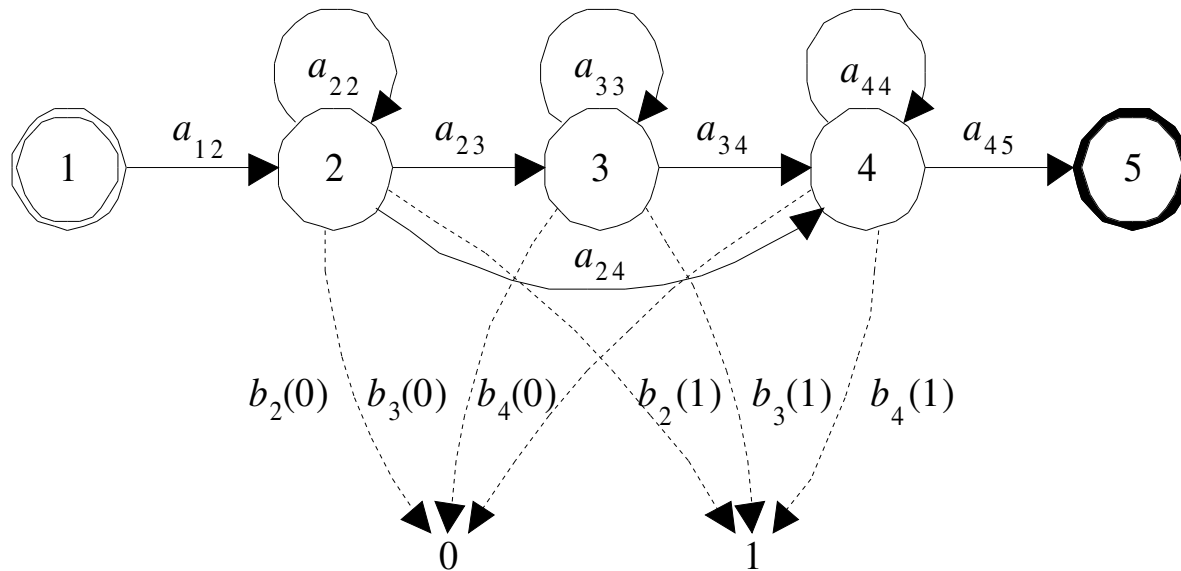
$$P(T) = 1 - P_2$$

O = H H T T H T H H T T H ...

S = 2 1 1 2 2 2 1 2 2 1 2 ...



# MOM Izquierda-Derecha



$$A = \begin{bmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 1/4 & 1/4 & 1/2 & 0 \\ 0 & 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad B = \begin{bmatrix} 0 & 1/3 & 1/5 & 2/3 & 0 \\ 0 & 2/3 & 4/5 & 1/3 & 0 \end{bmatrix}$$

- El estado 1 es el estado inicial y el 5 el final y se denominan no emisores.
- En esta configuración se puede observar la particularidad de que las transiciones se dan solamente de izquierda a derecha.
- Es el más utilizado para el caso de señales.
- ¿Cómo cálculo la probabilidad de la secuencia de salida 0010?

# MOM Izda-Dcha


Secuencias de de estados	Probabilidades de transición	Probabilidades de observación	Probabilidades de la secuencia
1, 2, 2, 2, 4, 5	$1 \frac{1}{4} \frac{1}{4} \frac{1}{2} \frac{1}{2} = \frac{1}{64}$	$\frac{1}{3} \frac{1}{3} \frac{2}{3} \frac{2}{3} = \frac{4}{81}$	$\frac{1}{1296}$
1, 2, 2, 3, 4, 5	$1 \frac{1}{4} \frac{1}{4} \frac{1}{2} \frac{1}{2} = \frac{1}{64}$	$\frac{1}{3} \frac{1}{3} \frac{4}{5} \frac{2}{3} = \frac{8}{135}$	$\frac{1}{1080}$
1, 2, 2, 4, 4, 5	$1 \frac{1}{4} \frac{1}{2} \frac{1}{2} \frac{1}{2} = \frac{1}{32}$	$\frac{1}{3} \frac{1}{3} \frac{1}{3} \frac{2}{3} = \frac{2}{81}$	$\frac{1}{1296}$
1, 2, 3, 3, 4, 5	$1 \frac{1}{4} \frac{1}{2} \frac{1}{2} \frac{1}{2} = \frac{1}{32}$	$\frac{1}{3} \frac{1}{5} \frac{4}{5} \frac{2}{3} = \frac{8}{225}$	$\frac{1}{900}$
1, 2, 3, 4, 4, 5	$1 \frac{1}{4} \frac{1}{2} \frac{1}{2} \frac{1}{2} = \frac{1}{32}$	$\frac{1}{3} \frac{1}{5} \frac{1}{3} \frac{2}{3} = \frac{2}{135}$	$\frac{1}{2160}$
1, 2, 4, 4, 4, 5	$1 \frac{1}{2} \frac{1}{2} \frac{1}{2} \frac{1}{2} = \frac{1}{16}$	$\frac{1}{3} \frac{2}{3} \frac{1}{3} \frac{2}{3} = \frac{4}{81}$	$\frac{1}{324}$

Probabilidad para todos los caminos posibles para generar la secuencia de salida 0010 en el ejemplo.

Probabilidad Total

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1/4 & 1/4 & 1/2 & 0 \\ 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 1/2 & 1/2 \\ 0 & 0 & 0 & 0 \end{bmatrix} B = \begin{bmatrix} 1/3 & 1/5 & 2/3 & 0 \\ 2/3 & 4/5 & 1/3 & 0 \end{bmatrix}$$

$$\Sigma = \frac{77}{10800} \approx 0,007$$



# Formalizando...

- Un MOM se caracteriza por:
  - Un conjunto de  $N$  estados  $E$ .
  - Un espacio de características observables. Un conjunto  $Y$  de  $M$  símbolos (MOM discretos).
  - Una matriz  $A = \{a_{ij}\}$  de probabilidad de transición entre estados. El elemento  $a_{ij}$  indica la probabilidad de transitar al estado  $j$  si se está en el estado  $i$ .

- Se cumple:  $a_{ij} \geq 0, \quad 1 \leq i, j \leq N;$

$$\sum_{j=1}^N a_{ij} = 1, \quad 1 \leq i \leq N.$$

# Formalizando...

- Una distribución de probabilidad de emisión de símbolos en cada estado:  $B = \{b_j(k)\}$  , para  $1 \leq j \leq N$ ,  $1 \leq k \leq M$ .
- El elemento  $b_j(k)$  indica la probabilidad de emitir una observación  $k$  en el estado  $j$ .
- Se cumple:  $b_i(k) \geq 0$ ,  $1 \leq i \leq N$ ,  $1 \leq k \leq M$ ;

$$\sum_{k=1}^M b_i(k) = 1, \quad 1 \leq i \leq N.$$

¡Ojo estados iniciales y finales!

# Formalizando...

- Una distribución de probabilidad de estado inicial:  $\Pi = \{\pi_i\}$ , para  $1 \leq i \leq N$ .
- El elemento  $\pi_i$  indica la probabilidad de que el primer estado en el que estamos (y desde el que se emite el primer símbolo) sea el estado  $i$ .
- Se cumple:  $\pi_i \geq 0, \quad 1 \leq i \leq N;$

$$\sum_{i=1}^N \pi_i = 1, \quad 1 \leq i \leq N.$$

- Un modelo queda descrito, pues, con  $\lambda = (E, Y, A, B, \Pi)$ .

# Los problemas básicos de los MOM

- **Problema 1:** El problema de la evaluación. Dada una secuencia de observaciones  $O = o_1 o_2 \dots o_T$  y un modelo  $\lambda = (A, B)$ , ¿cómo calculamos *eficientemente* la probabilidad de que  $\lambda$  genera a  $O$ , es decir,  $P(O \mid \lambda)$ ?
  - Algoritmo *forward-backward*
- **Problema 2:** El problema de la decodificación. Dada una secuencia de observaciones  $O$  y un modelo  $\lambda = (A, B)$ , ¿cómo calculamos la secuencia de estados  $x_0, x_1, \dots, x_{T+1}$  que mejor “explica” las observaciones?
  - Algoritmo de Viterbi
- **Problema 3:** El problema del entrenamiento. Dada una secuencia de observaciones  $O$ , ¿cómo estimamos los parámetros de  $\lambda = (A, B)$  para que  $P(O \mid \lambda)$  sea máxima?
  - Algoritmo *EM*




# Aplicaciones

## Los autómatas como modelos de señales

- ☐ Modelos de señales temporales
- ☐ Utilización en:
  - Clasificación: reconocimiento de patrones, señales 2D (imágenes) o N-dimensional.
  - Generación de señales sintéticas

# Bioinformática

- **Generación de secuencias de aminoácidos:**



Estado D: codifica proteínas

$P(A)=P(T)=P(G)=P(C)=0.25$

Estado N: no codifica proteínas


$P(A)=P(T)=P(C)=0.1; P(G)=0.7$

Secuencia observada: ATGTTACTAC.....GGGGTGGAG...




# Reconocimiento de Patrones


## Ejemplo con habla



# “Estructura” de la Señal De Voz




# Modelado acústico de fonemas




¿Estados?

# Modelado acústico de fonemas

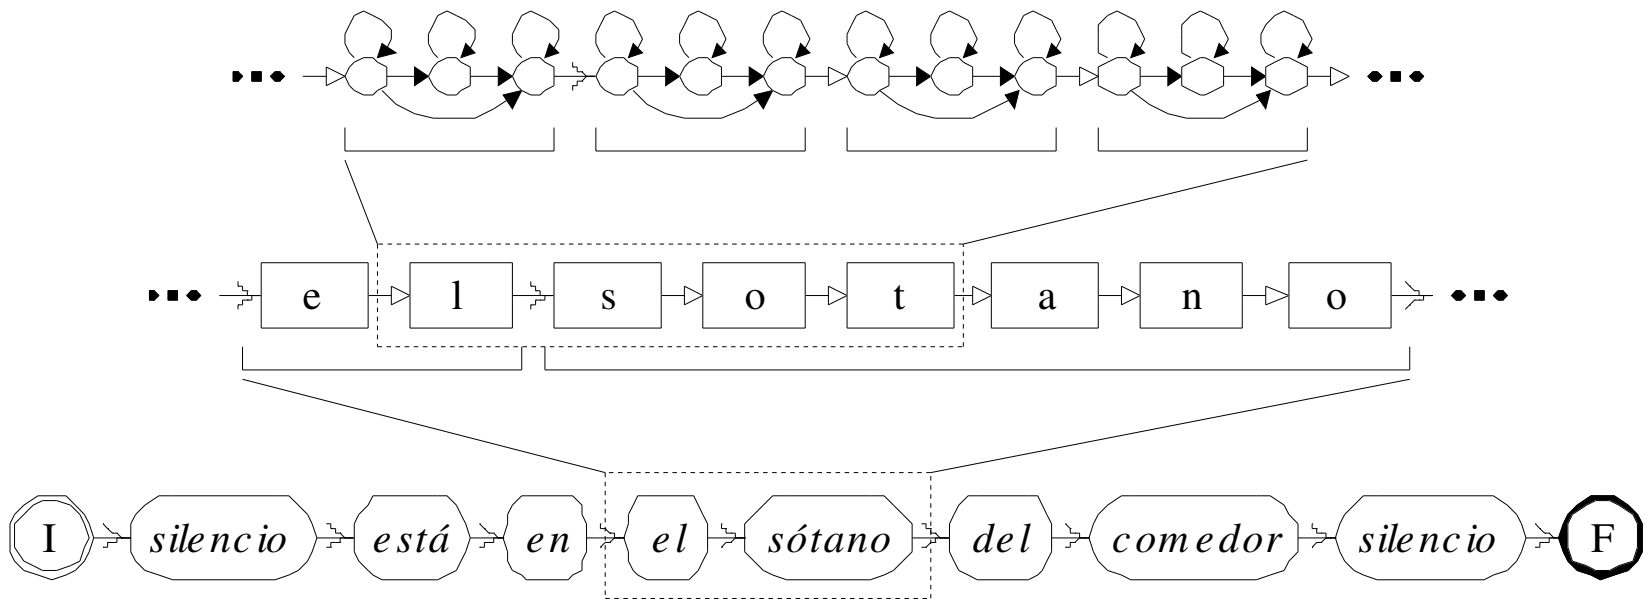
- Asimilamos estados a configuraciones del aparato fonador. De una configuración se puede pasar a otra de acuerdo con ciertas reglas probabilísticas.



# Modelado del lenguaje





# Modelado compuesto



- **Modelo compuesto para la frase: *Está en el sótano del comedor*. Se pueden observar los tres niveles de la composición: los estados del modelo acústico, el diccionario fonético y el modelo de lenguaje. En los modelos acústicos se han eliminado los estados no emisores para simplificar el esquema.**



# Reconocimiento de sonidos masticatorios en rumiantes

masticación



# Reconocimiento de sonidos masticatorios en rumiantes


arranque







# Reconocimiento de sonidos masticatorios en rumiantes

Un autómatas por tipo de señal



# Reconocimiento de sonidos masticatorios en rumiantes

Decisión por el autómata más representativo



# OCR manuscrito

DAR LA OPORTUNIDAD A  
QUE UNA PERSONA QUE  
LLEVA BASTANTE TIEMPO  
CONFIA EN TELEFONICA  
OPREBRSELO OTRO IT. AD

SIEMPRE LLEGAN TARDE  
LAS OFERTAS Y REGALOS




LAS HORAS A LAS QUE SE  
RECIBE LOS ~~COMBO~~ MENSAJES  
SOBRE LOS SERVICIOS DE  
NOVI STAR

- DEBERÍA TENER UN  
SERVICIO DE NOTICIAS  
COMPLETAMENTE GRATIS

# OCR manuscrito





Entrada:  
imagen





Salida:  
texto



# Clasificación de cromosomas



# Detección de cáncer de próstata en US



Tejido normal



Tejido con cáncer



# Otras señales modelizables

- “Ruidos” cardíacos.
- Señal de VFC
- EEG.
- ECG.
- ....

# Bibliografía

- J. Deller, J. Proakis, J. Hansen, “Discrete Time Processing of Speech Signals”. Macmillan Publishing, New York, 1993.
- H. Fletcher, “Speech and Hearing in Communication”, Van Nostrand, New York, NY, 1953.
- L. Rocha, “Procesamiento de voz”, I Escola Brasileiro-Argentina de Informática, (Kapelusz, 1987).
- A. M. Borzone, “Manual de Fonética Acústica”, Hachette, 1980.
- Lawrence Rabiner, Biing-Hwang Juang, “Fundamentals of speech recognition”. Prentice Hall. 1993.
- Steve Young et al., The HTK book (<http://htk.eng.cam.ac.uk/>)
- Frederick Jelinek, “Statistical Methods for Speech Recognition”. The MIT Press. 1998.